

Codage de l'information

Rakotoarimalala Tsinjo Tony

Cours 5
IT University - 2023

CODES À LONGUEUR FIXE

On dit d'un code qu'il est de *longueur fixe* lorsque tous les mots qu'il contient ont la même longueur. Autrement dit $C \subset \mathcal{A}^*$ est un code de longueur fixe s'il existe un entier non nul n tel que

$$C \subset \mathcal{A}^n$$

CODES À LONGUEUR FIXE

On dit d'un code qu'il est de *longueur fixe* lorsque tous les mots qu'il contient ont la même longueur. Autrement dit $C \subset \mathcal{A}^*$ est un code de longueur fixe s'il existe un entier non nul n tel que

$$C \subset \mathcal{A}^n$$

Exemple

- Les 128 mots (octets) utilisés pour le codage ASCII forment un code de longueur fixe.
- Le code associé à l'un quelconque des codages **ISO-8859** est un code de longueur fixe.

CODES À VIRGULE

Les CODES À VIRGULE sont des codes pour lesquels un symbole (ou un groupe de symboles) de \mathcal{A} est réservé pour marquer le début ou la fin des mots du code.

Ce symbole particulier est appelé **une virgule**. Il permet de factoriser un message codé avec ce code

Exemple

- *Le Morse est un codage à virgule*

CODES PRÉFIXES

Un langage préfixe est un langage dans lequel aucun mot n'est le préfixe d'un autre mot du langage. Dit autrement, $L \subset \mathcal{A}^*$ est préfixe si pour tous mots $u, v \in L$, on a

$$u \notin \text{Pref}(v) \text{ et } v \notin \text{Pref}(u).$$

CODES PRÉFIXES

Un langage préfixe est un langage dans lequel aucun mot n'est le préfixe d'un autre mot du langage. Dit autrement, $L \subset \mathcal{A}^*$ est préfixe si pour tous mots $u, v \in L$, on a

$$u \notin \text{Pref}(v) \text{ et } v \notin \text{Pref}(u).$$

Exemple

- *Le langage $L = \{00, 010, 10, 110, 111\}$ est préfixe*
- *Les langages de longueur fixe sont des langages préfixes.*

CODES PRÉFIXES

Un langage préfixe est un langage dans lequel aucun mot n'est le préfixe d'un autre mot du langage. Dit autrement, $L \subset \mathcal{A}^*$ est préfixe si pour tous mots $u, v \in L$, on a

$$u \notin \text{Pref}(v) \text{ et } v \notin \text{Pref}(u).$$

Exemple

- *Le langage $L = \{00, 010, 10, 110, 111\}$ est préfixe*
- *Les langages de longueur fixe sont des langages préfixes.*

Théorème

Tout langage préfixe autre que $\{\epsilon\}$ est un code.

Démos: À faire comme exercice

RÉSIDUEL D'UN LANGAGE

LE RÉSIDUEL À GAUCHE d'un langage $L \subset \mathcal{A}^*$ par un mot $u \in \mathcal{A}^*$ est le langage que l'on obtient en ne gardant des mots de L que ceux admettant u comme préfixe, et en supprimant ce préfixe de ces mots. En notant $u^{-1}.L$ ce résiduel, on a

$$u^{-1}.L = \{v \in \mathcal{A}^* \mid u.v \in L\}$$

(on peut définir le résiduel à droite de manière équivalente mais on n'utilisera pas cette notion dans le cours).

RÉSIDUEL D'UN LANGAGE

LE RÉSIDUEL À GAUCHE d'un langage $L \subset \mathcal{A}^*$ par un mot $u \in \mathcal{A}^*$ est le langage que l'on obtient en ne gardant des mots de L que ceux admettant u comme préfixe, et en supprimant ce préfixe de ces mots. En notant $u^{-1}.L$ ce résiduel, on a

$$u^{-1}.L = \{v \in \mathcal{A}^* \mid u.v \in L\}$$

(on peut définir le résiduel à droite de manière équivalente mais on n'utilisera pas cette notion dans le cours).

Exemple

Avec le langage $L = \{00, 01, 110, 001\}$

- si $u_1 = 10$ alors $u_1^{-1}.L = \emptyset$
- si $u_2 = 1$ alors $u_2^{-1}.L = \{10\}$
- si $u_3 = 00$ alors $u_3^{-1}.L = \{\epsilon, 1\}$

QUOTIENT D'UN LANGAGE

Le QUOTIENT À GAUCHE D'UN LANGAGE $L \subset \mathcal{A}^*$ par un langage $M \subset \mathcal{A}^*$ est le langage obtenu en ne gardant que les mots de L ayant un préfixe dans M et en supprimant ce préfixe des mots gardés. En notant $M^{-1}.L$ ce quotient, on a

$$M^{-1}.L = \{v \in \mathcal{A}^* | \exists u \in M \text{ tel que } u.v \in L\}$$

Autrement dit

$$M^{-1}.L = \bigcup_{u \in M} u^{-1}.L$$

QUOTIENT D'UN LANGAGE

Le QUOTIENT À GAUCHE D'UN LANGAGE $L \subset \mathcal{A}^*$ par un langage $M \subset \mathcal{A}^*$ est le langage obtenu en ne gardant que les mots de L ayant un préfixe dans M et en supprimant ce préfixe des mots gardés. En notant $M^{-1}.L$ ce quotient, on a

$$M^{-1}.L = \{v \in \mathcal{A}^* | \exists u \in M \text{ tel que } u.v \in L\}$$

Autrement dit

$$M^{-1}.L = \bigcup_{u \in M} u^{-1}.L$$

Exemple

En reprenant l'exemple ci-dessus, et en posant $M = \{u_1, u_2, u_3\}$ alors

$$M^{-1}.L = \{\epsilon, 1, 10\}$$

ALGORITHME DE SARDINAS ET PATTERSON

Soit $L \subset \mathcal{A}^*$ un langage. On définit à partir de L une suite (L_n) de langage en posant

$$L_0 = L \tag{1}$$

$$L_1 = L^{-1}.L - \{\epsilon\} \tag{2}$$

$$L_{n+1} = L^{-1}.L_n \cup L_n^{-1}.L \text{ pour tout } n \geq 1 \tag{3}$$

ALGORITHME DE SARDINAS ET PATTERSON

Soit $L \subset \mathcal{A}^*$ un langage. On définit à partir de L une suite (L_n) de langage en posant

$$L_0 = L \tag{1}$$

$$L_1 = L^{-1}.L - \{\epsilon\} \tag{2}$$

$$L_{n+1} = L^{-1}.L_n \cup L_n^{-1}.L \text{ pour tout } n \geq 1 \tag{3}$$

Théorème

Un langage $L \subset \mathcal{A}^$ est un code si et seulement si le mot vide n'appartient à aucun des langages L_n de la suite définie ci-dessus.*

Demos: à admettre

- 1 Lorsque L est un langage de longueur fixe (non nulle), alors $L_1 = L^{-1}.L - \{\epsilon\} = \emptyset$, et par conséquent, pour tout entier $n \geq 2$, $L_n = \emptyset$. Le mot vide n'est dans aucun langage L_n , et L est bien évidemment un code.

APPLICATIONS

- ① Lorsque L est un langage de longueur fixe (non nulle), alors $L_1 = L^{-1}.L - \{\epsilon\} = \emptyset$, et par conséquent, pour tout entier $n \geq 2$, $L_n = \emptyset$. Le mot vide n'est dans aucun langage L_n , et L est bien évidemment un code.
- ② Lorsque L est un langage préfixe (autre que le langage réduit au seul mot vide), $L_1 = \emptyset$ et il en est de même pour tous les langages L_n avec $n \geq 2$. Et tout langage préfixe est un code.

Pour le langage $L = \{1, 00, 01, 10\}$,

Pour le langage $L = \{1, 00, 01, 10\}$,
on a

$$L_1 = \{0\}$$

$$L_2 = \{0, 1\}$$

$$L_3 = \{0, 1, \epsilon\}$$

Puisque $\epsilon \in L_3$ donc L n'est pas un code.

En effet on a bien une double factorisation du mot 1001 avec des mots de L :

$$1001 = \underbrace{10} \cdot \underbrace{01} = \underbrace{1} \cdot \underbrace{00} \cdot \underbrace{1}$$

Enfin pour le langage $L = \{000, 010, 011, 01001\}$,

Enfin pour le langage $L = \{000, 010, 011, 01001\}$, on a

$$L_1 = \{01\}$$

$$L_2 = \{0, 1, 001\}$$

$$L_3 = \{00, 10, 11, 1001\}$$

$$L_4 = \{0\}$$

$$L_5 = \{00, 10, 11, 1001\}$$

Comme $L_3 = L_5$, on en déduit que tout indice pair de la suite L_n vaut L_4 et les impairs vaut L_3 . Donc ϵ n'apparaît dans aucun de tous les L_i .
Donc L est un code.

Écrire un programme en python (ou n'importe quel langage) qui décide si un langage donné en argument est un code ou pas.